Benemérita Universidad Autónoma de Puebla

Facultad de ciencias de la computación

Ingeniería en ciencias de la computación

Minería de Datos

NRC

25873

Manual de usuario

Nombres de los integrantes

Manuel Montes Pioquinto

Contenido

Manual de usuario: LDA Studio 3

Instalación 3

Panel de control (izquierda) 4

Resultados 7

Instrucciones de uso 8

Manual de usuario: LDA Studio

LDA Studio es una herramienta de interfaz gráfica diseñada para el modelado de temas utilizando el algoritmo Latent Dirichlet Allocation (LDA). Su objetivo es optimizar el flujo de trabajo en minería de texto, ofreciendo compatibilidad con múltiples formatos de entrada (CSV, DOCX, PDF, TXT) y un control preciso sobre los hiperparámetros del análisis (α, β y cantidad de tópicos k).

Características Principales:

- **Núcleo de cálculo en C:** Implementación del algoritmo LDA mediante un *backend* optimizado en lenguaje C, garantizando alto rendimiento en el procesamiento de grandes volúmenes de datos.
- **Procesamiento paralelo:** Ejecución multihilo que permite la generación simultánea de modelos con diferentes valores de k.
- **Visualización de resultados:**
    - **Gráfico de Entropía:** Visualización comparativa para identificar el número óptimo de tópicos basándose en la reducción de la entropía.
    - **Ranking de Tópicos:** Tablas detalladas que destacan los temas con menor entropía y mayor coherencia semántica.
- **Persistencia y Reutilización:** Capacidad para cargar resultados previamente calculados, facilitando el análisis posterior sin requerir una reprocesamiento del corpus.

Instalación

El software es portable y no requiere instalación en el sistema, solo descargue y ejecute el archivo LDA Studio.exe

3.- Uso de la interfaz:

La interfaz se divide en dos secciones, el panel del control a la izquierda y un área de visualización a la derecha.

Panel de control (izquierda)

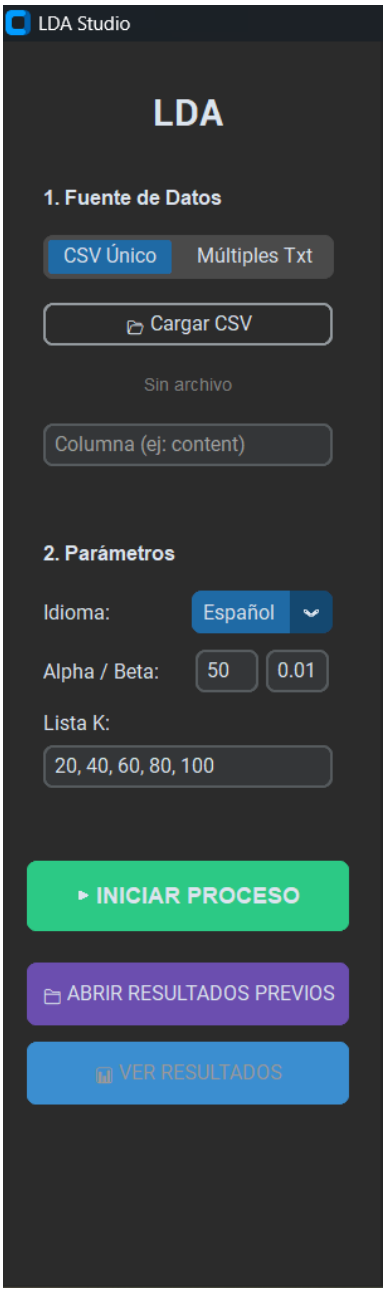

1.-Elegir entrada: En la parte superior permite elegir entre un CSV único o Múltiples textos, después se abrirá una pantalla de documentos, donde se podrá elegir el CSV o los múltiples textos

2.- parámetros de ejecución: en esta sección se puede elegir las opciones para la ejecución del LDA, como la columna del CSV, idioma del texto, Alpha/Beta y los tópicos separados por comas

3.- Botones de uso: En la parte inferior se encuentran los 3 botones principales para el uso de la interfaz

- Iniciar Proceso: botón que crea los archivos de configuración, así como el vocabulario y corpus del documento de texto, y ejecuta el LDA para los diferentes tópicos
- Abrir Resultados Previos:
- Permite seleccionar una carpeta con nombre salida, que contenga los resultados previos a una ejecución

Ver resultados: una vez con el LDA terminado o con los resultados previos cargados, se activa y permite ver la gráfica y la tabla con los 20 mejores tópicos

Panel de resultados (derecho):

Gráfica

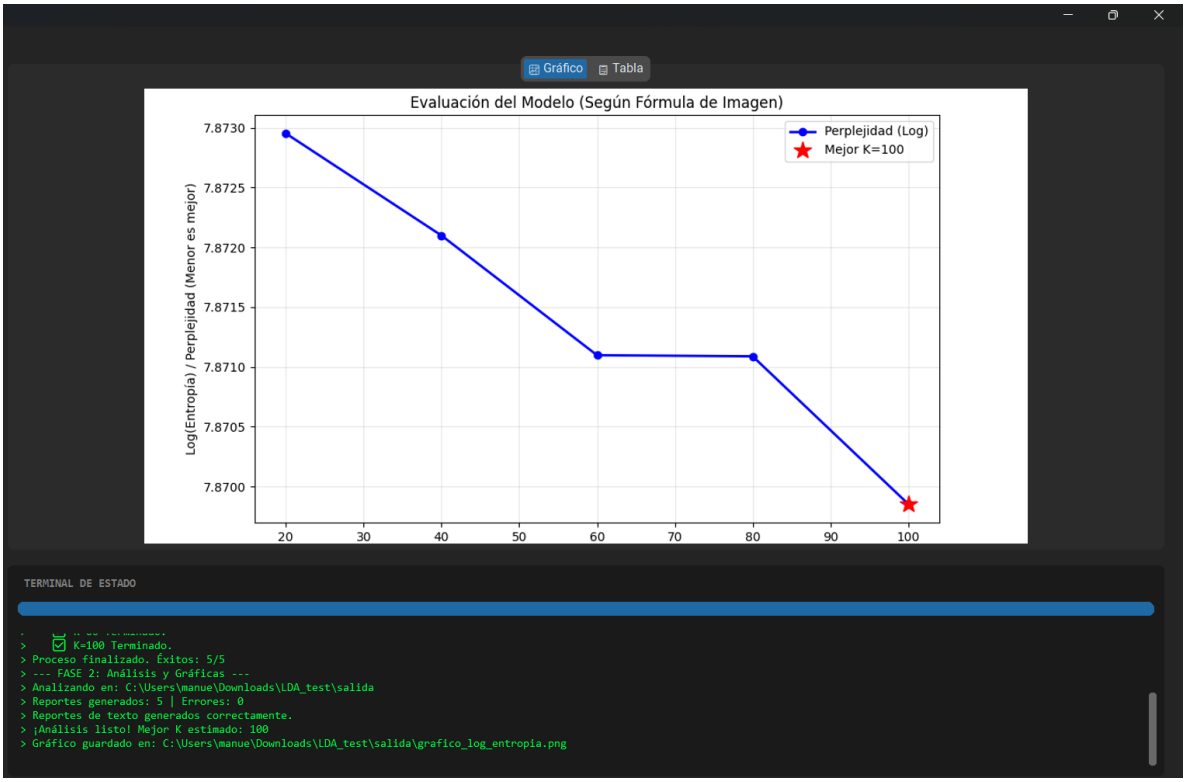

En la parte superior mostrará una gráfica de la entropía de cada tópico, mostrando con una estrella el mejor resultado. En la parte inferior se podrá ver una salida de texto en forma de comandos que indica el estado de la ejecución

Tabla

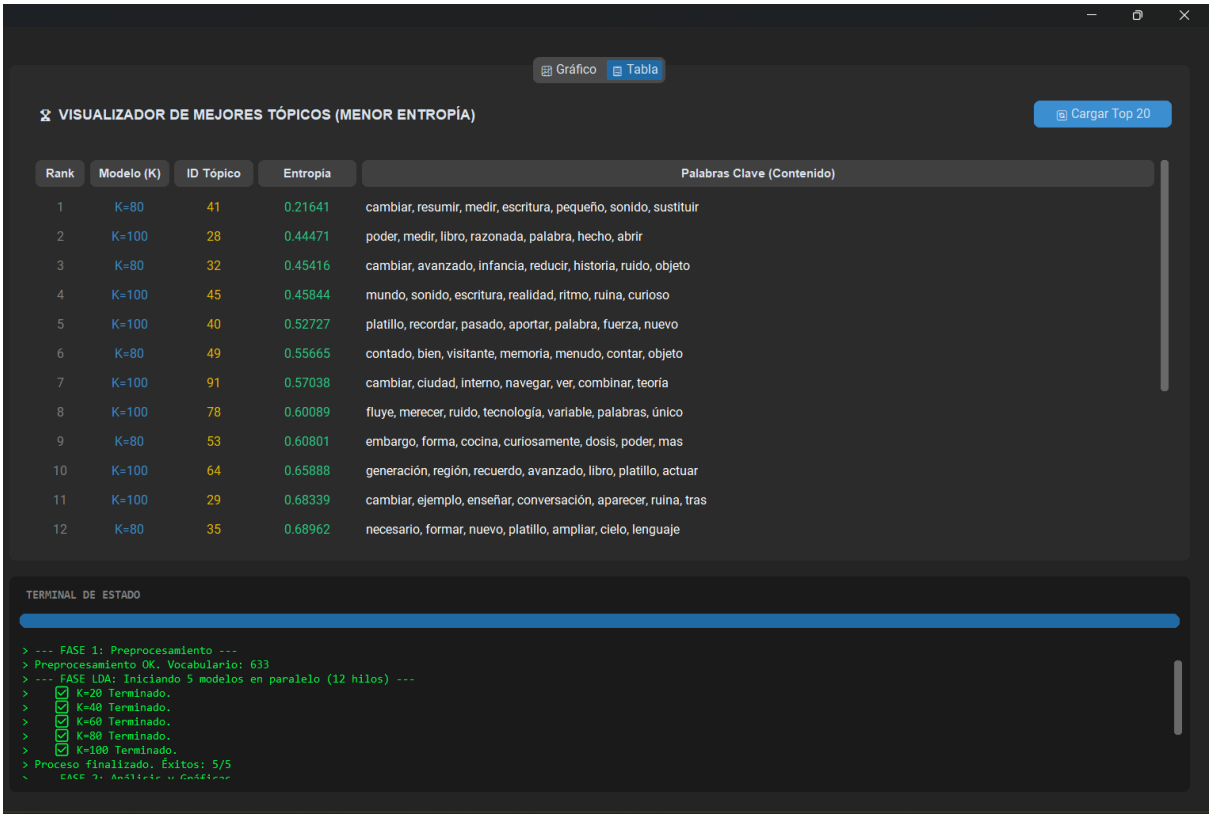

Rank	Modelo (K)	ID Tópico	Entropía	Palabras Clave (Contenido)
1	K=80	41	0.21641	cambiar, resumir, medir, escritura, pequeño, sonido, sustituir
2	K=100	28	0.44471	poder, medir, libro, razonada, palabra, hecho, abrir
3	K=80	32	0.45416	cambiar, avanzado, infancia, reducir, historia, ruido, objeto
4	K=100	45	0.45844	mundo, sonido, escritura, realidad, ritmo, ruina, curioso
5	K=100	40	0.52727	platillo, recordar, pasado, aportar, palabra, fuerza, nuevo
6	K=80	49	0.55665	contado, bien, visitante, memoria, menudo, contar, objeto
7	K=100	91	0.57038	cambiar, ciudad, interno, navegar, ver, combinar, teoría
8	K=100	78	0.60089	fluye, merecer, ruido, tecnología, variable, palabras, único
9	K=80	53	0.60801	embargo, forma, cocina, curiosamente, dosis, poder, mas
10	K=100	64	0.65888	generación, región, recuerdo, avanzado, libro, platillo, actuar
11	K=100	29	0.68339	cambiar, ejemplo, enseñar, conversación, aparecer, ruina, tras
12	K=80	35	0.68962	necesario, formar, nuevo, platillo, ampliar, cielo, lenguaje

Muestra el ranking de los mejores tópicos, con menor entropía, en la primera columna muestra su posición dentro del ranking, en la segunda la cantidad de tópicos usados, en la tercera el id del tópico exacto, en la cuarta su nivel de entropía y en la quinta muestra las primeras palabras con mayor probabilidad

Resultados

Después de una ejecución y muestra de los resultados, se genera una carpeta llamada salida, donde estarán las carpetas con los resultados crudos de la ejecución

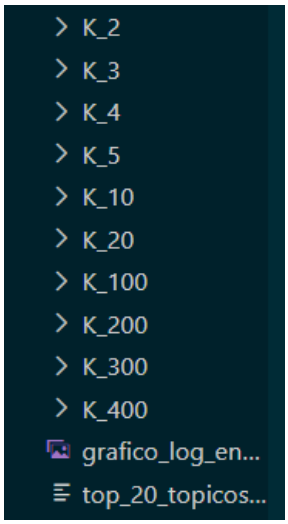

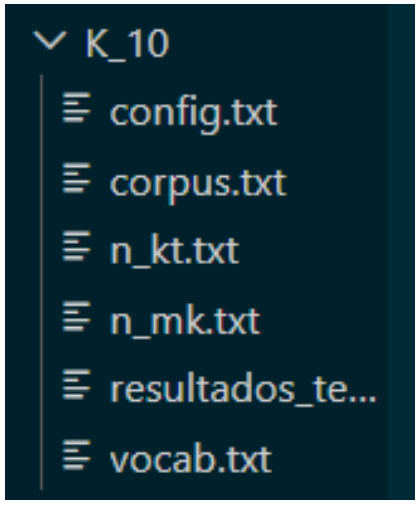

Donde dentro de cada carpeta estara el corpus, la configuracion usada, sus matrices n_kt y n_mk, aparte de todos los resultados y el vocabulario

Ejemplo de lo que se encontrara dentro de archivo resultados

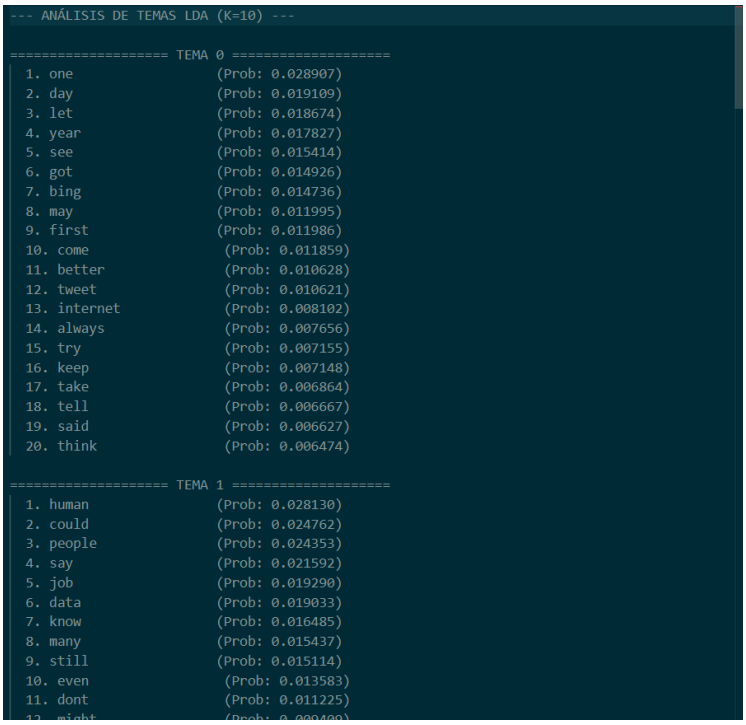

```
--- ANÁLISIS DE TEMAS LDA (K=10) ---

==================== TEMA 0 ====================
  1. one                  (Prob: 0.028907)
  2. day                  (Prob: 0.019109)
  3. let                  (Prob: 0.018674)
  4. year                 (Prob: 0.017827)
  5. see                  (Prob: 0.015414)
  6. got                  (Prob: 0.014926)
  7. bing                 (Prob: 0.014736)
  8. may                  (Prob: 0.011995)
  9. first                (Prob: 0.011986)
  10. come                 (Prob: 0.011859)
  11. better               (Prob: 0.010628)
  12. tweet                (Prob: 0.010621)
  13. internet             (Prob: 0.008102)
  14. always               (Prob: 0.007656)
  15. try                  (Prob: 0.007155)
  16. keep                 (Prob: 0.007148)
  17. take                 (Prob: 0.006864)
  18. tell                 (Prob: 0.006667)
  19. said                 (Prob: 0.006627)
  20. think                (Prob: 0.006474)

==================== TEMA 1 ====================
  1. human                (Prob: 0.028130)
  2. could                (Prob: 0.024762)
  3. people               (Prob: 0.024353)
  4. say                  (Prob: 0.021592)
  5. job                  (Prob: 0.019290)
  6. data                 (Prob: 0.019033)
  7. know                 (Prob: 0.016485)
  8. many                 (Prob: 0.015437)
  9. still                (Prob: 0.015114)
  10. even                 (Prob: 0.013583)
  11. dont                 (Prob: 0.011225)
  12. might                (Prob: 0.009409)
```

Instrucciones de uso

1. Inicio de la aplicación: Al ejecutar LDA Studio.exe, se desplegará la interfaz principal en modo ventana. El usuario puede redimensionar o ajustar la ventana según sus necesidades de visualización.

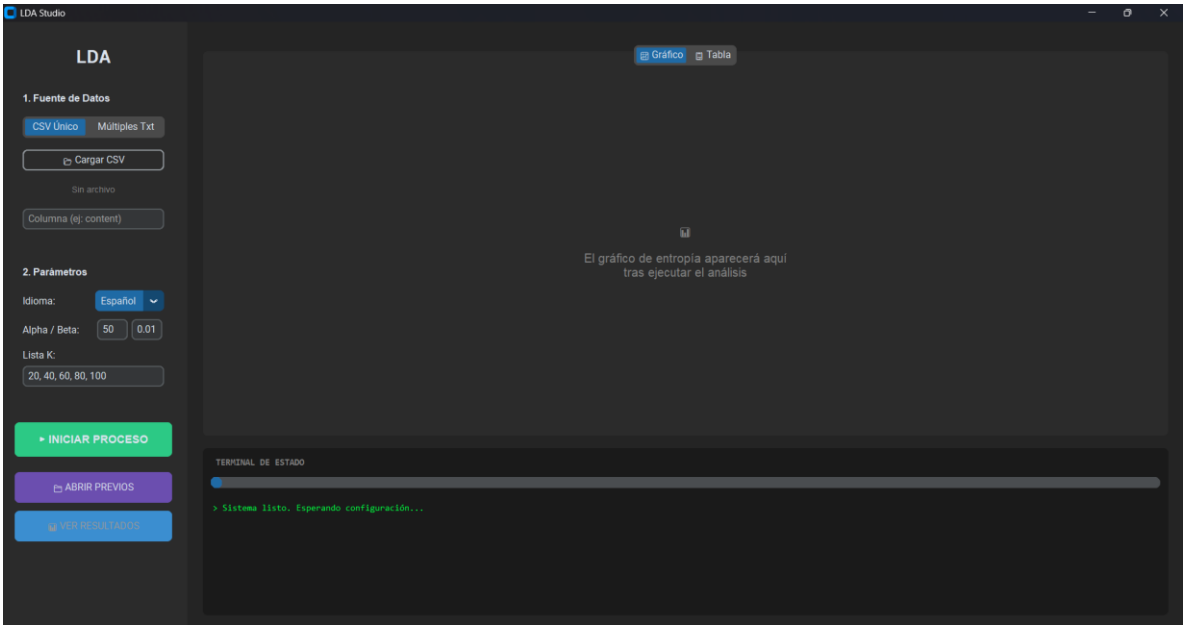

2.- Selección de Fuente de Datos: En el panel de control (izquierda), seleccione el tipo de entrada deseada: "CSV Único" o "Múltiples Txt".

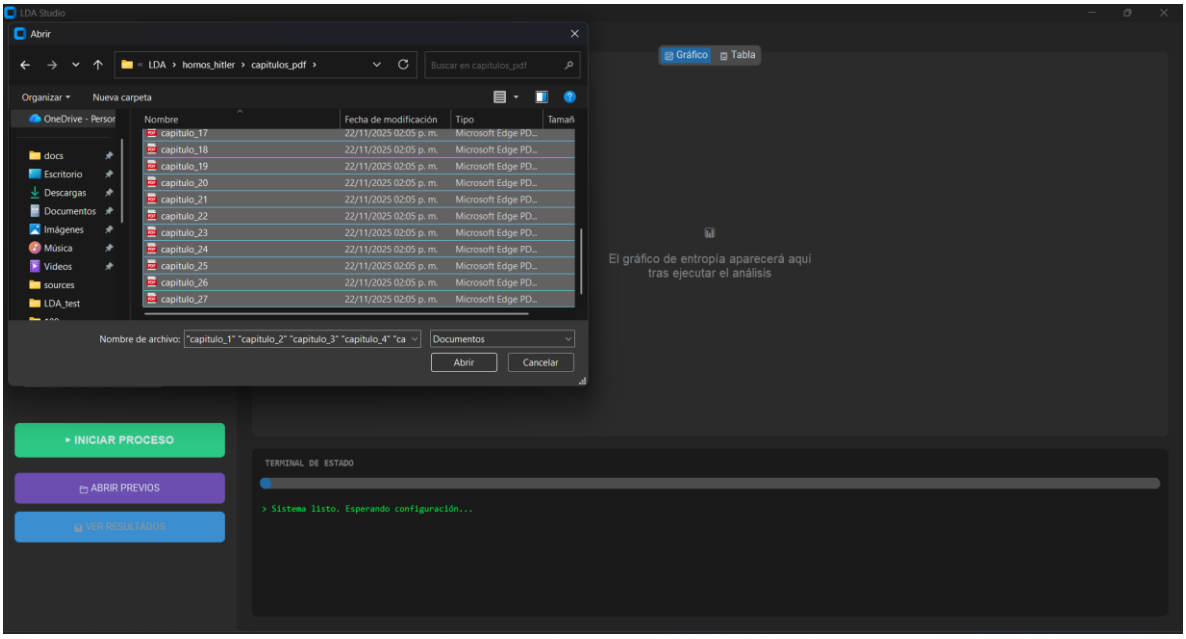

Archivos de Texto (PDF, DOCX, TXT): Se recomienda segmentar el texto en unidades

lógicas más pequeñas (por ejemplo: capítulos o secciones) para mejorar la granularidad del análisis.

Archivos CSV: Tras cargar el archivo, especifique el nombre de la columna que contiene el texto a analizar. La aplicación procesará automáticamente cada celda de dicha columna como un documento independiente.

3.- Configuración de Hiperparámetros:

Idioma: Seleccione el idioma predominante en el corpus.

Alpha / Beta: Defina los valores de los hiperparámetros. Se sugiere utilizar la heurística estándar donde α= 50 / k (cantidad de tópicos) y β = 0.01 para obtener resultados iniciales equilibrados.

Lista K: Ingrese los valores de k (cantidad de tópicos) que desea evaluar, separados por comas (ej. 20, 40, 60, 80, 100).

4. Procesamiento: Haga clic en el botón "Iniciar Proceso". La aplicación realizará el preprocesamiento del texto (limpieza y tokenización) y ejecutará el algoritmo LDA. Una ventana emergente notificará al usuario cuando el cálculo haya finalizado.

Nota: El tiempo de ejecución variará dependiendo de la cantidad de núcleos del procesador disponibles y el tamaño del vocabulario del corpus.

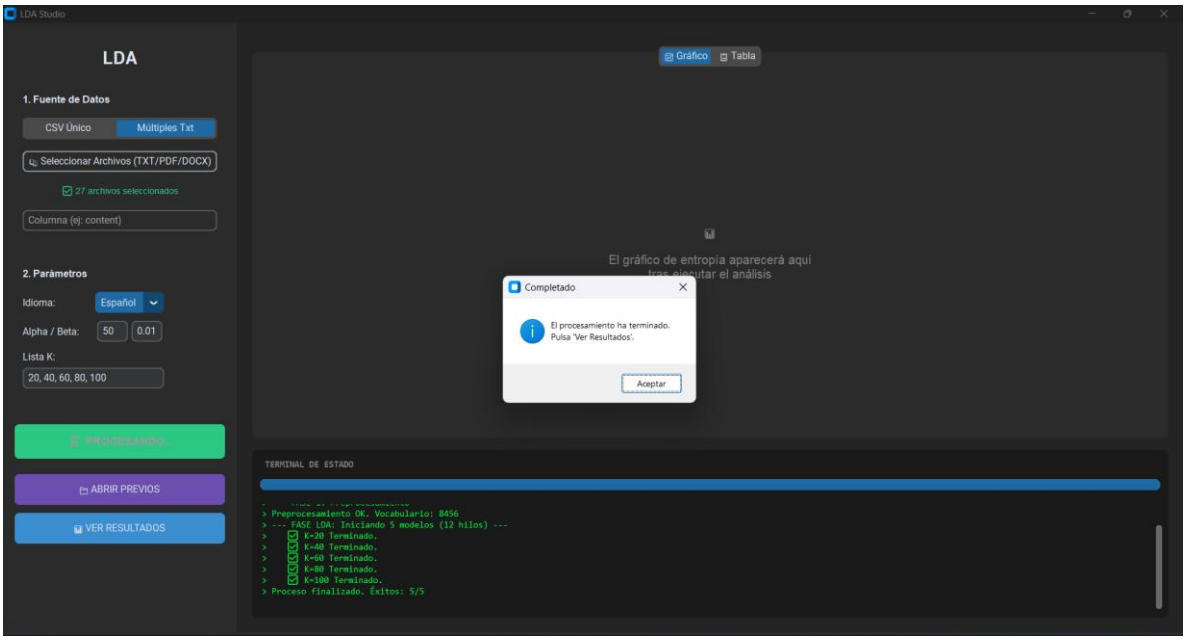

5.- ver resultados: Después de finalizar el LDA, abra la carpeta salida, que se generó en la misma carpeta donde está su texto y da click en “Ver resultado”.

Nota: el proceso puede tardar según el corpus

En la interfaz, podrá alternar entre la vista gráfica (Entropía vs Perplejidad) y la vista tabular con el ranking de los mejores tópicos encontrados.

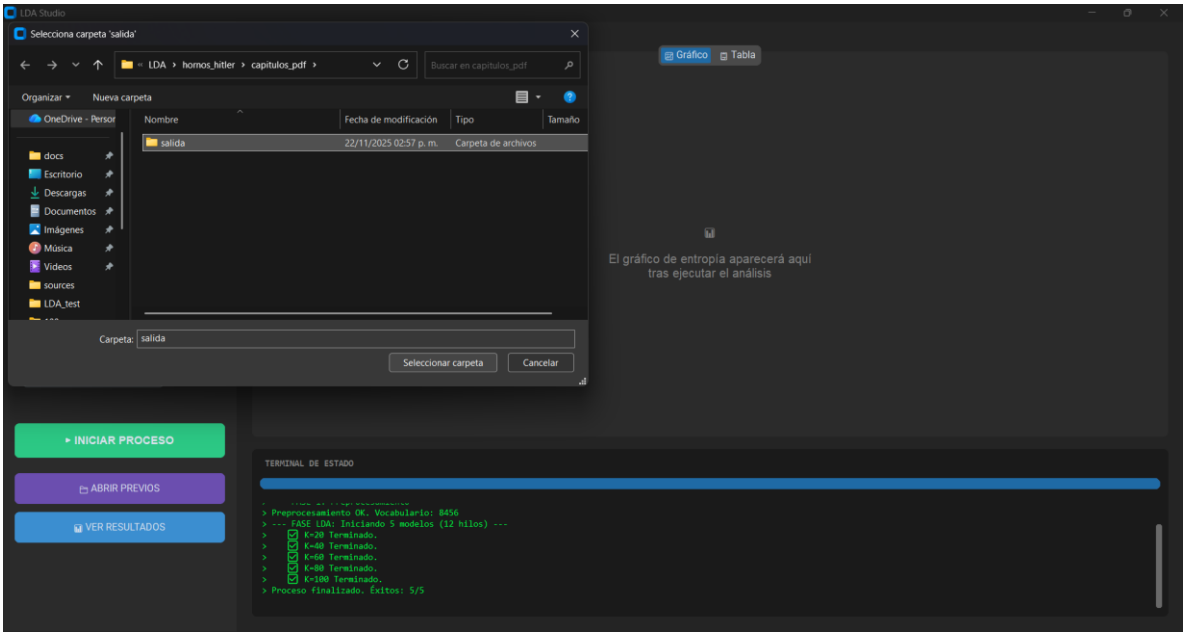

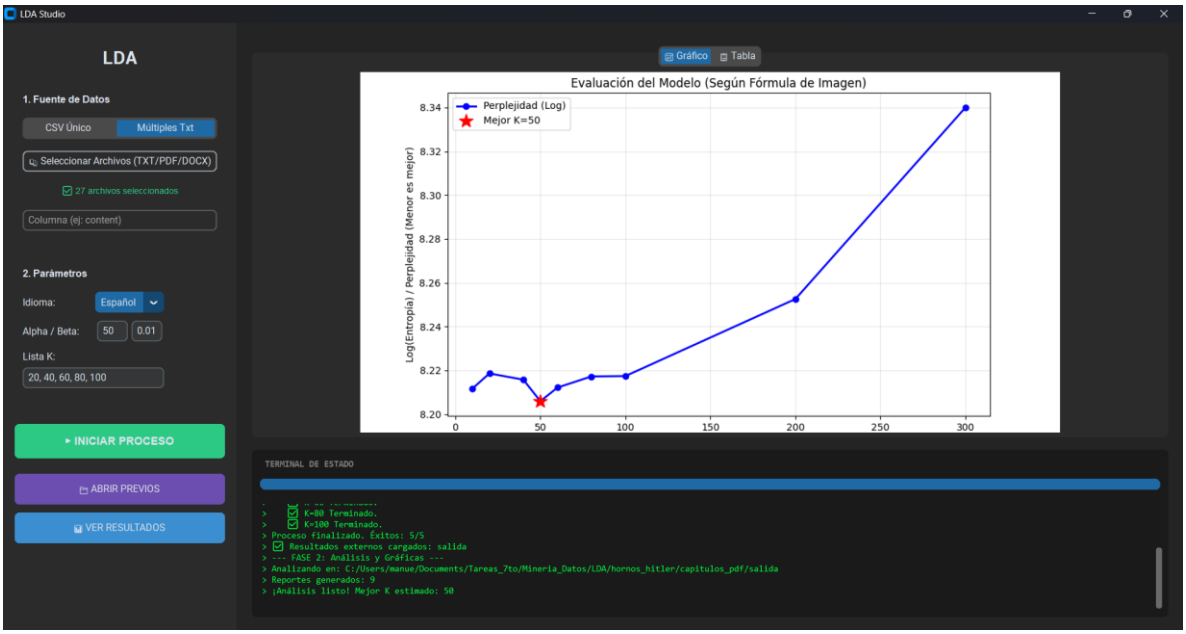

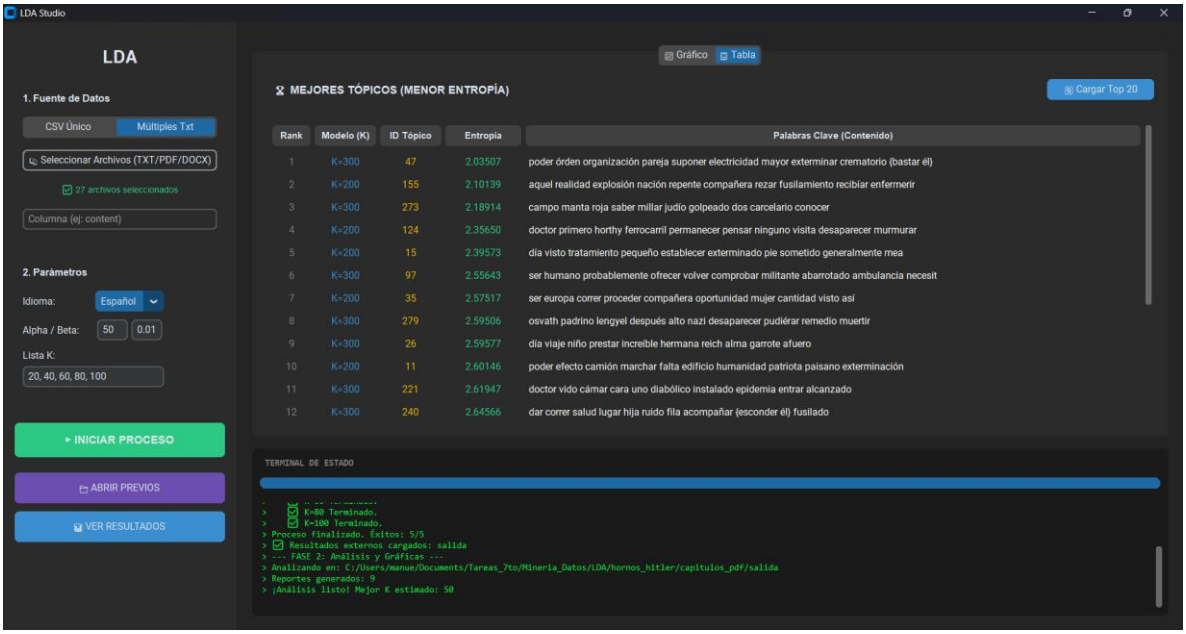

Rank	Modelo (K)	ID Tópico	Entropia	Palabras Clave (Contenido)
1	K=300	47	2.03507	poder órden organización pareja suponer electricidad mayor exterminar crematorio (bastar él)
2	K=200	155	2.10139	aquel realidad explosión nación repente compañera rezar fusilamiento recibíar enfermerir
3	K=300	273	2.18914	campo manta roja saber millar judío golpeado dos carcelario conocer
4	K=200	124	2.35650	doctor primero horthy ferrocarril permanecer pensar ninguno visita desaparecer murmurar
5	K=200	15	2.39573	día visto tratamiento pequeño establecer exterminado pie sometido generalmente mea
6	K=300	97	2.55643	ser humano probablemente ofrecer volver comprobar militante abarrotado ambulancia necesit
7	K=200	35	2.57517	ser europa correr proceder compañera oportunidad mujer cantidad visto así
8	K=300	279	2.59506	osvath padrino lengyel después alto nazi desaparecer pudiérar remedio muertir
9	K=300	26	2.59577	día viaje niño prestar increíble hermana reich alma garrote afuero
10	K=200	11	2.60146	poder efecto camión marchar falta edificio humanidad patriota paisano exterminación
11	K=300	221	2.61947	doctor vido cámar cara uno diabólico instalado epidemia entrar alcanzado
12	K=300	240	2.64566	dar correr salud lugar hija ruido fila acompañar (esconder él) fusilado